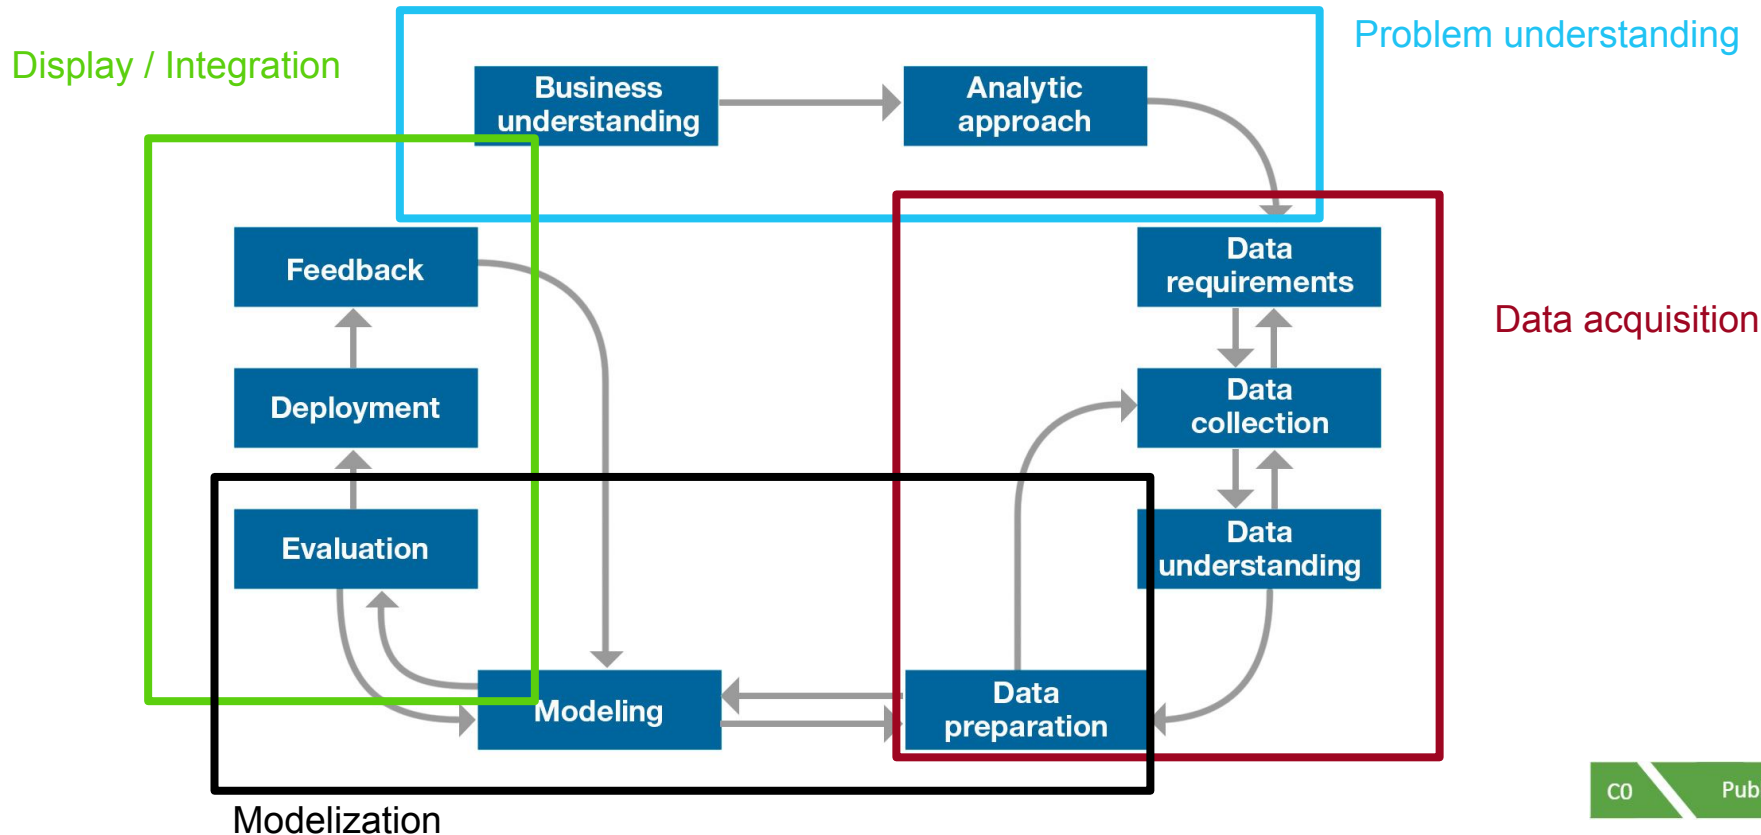




Data scientist presentation

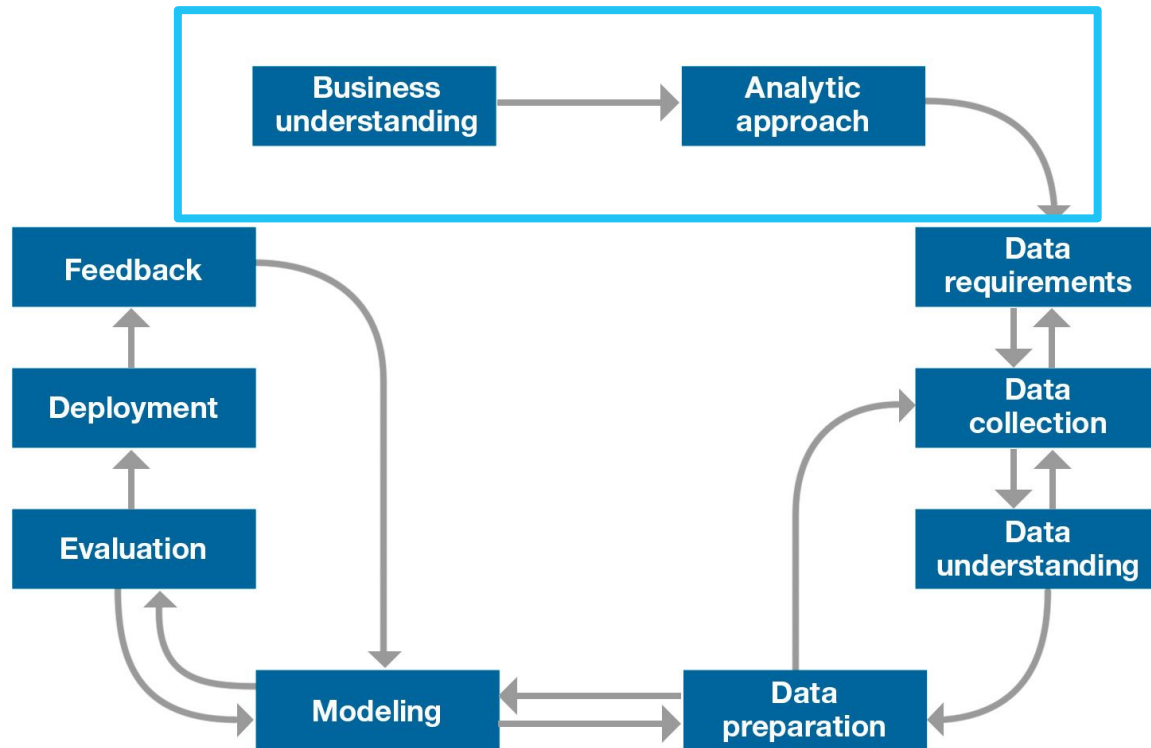
2023ko Otsailaren 9a

POSSIBLE ROADMAP

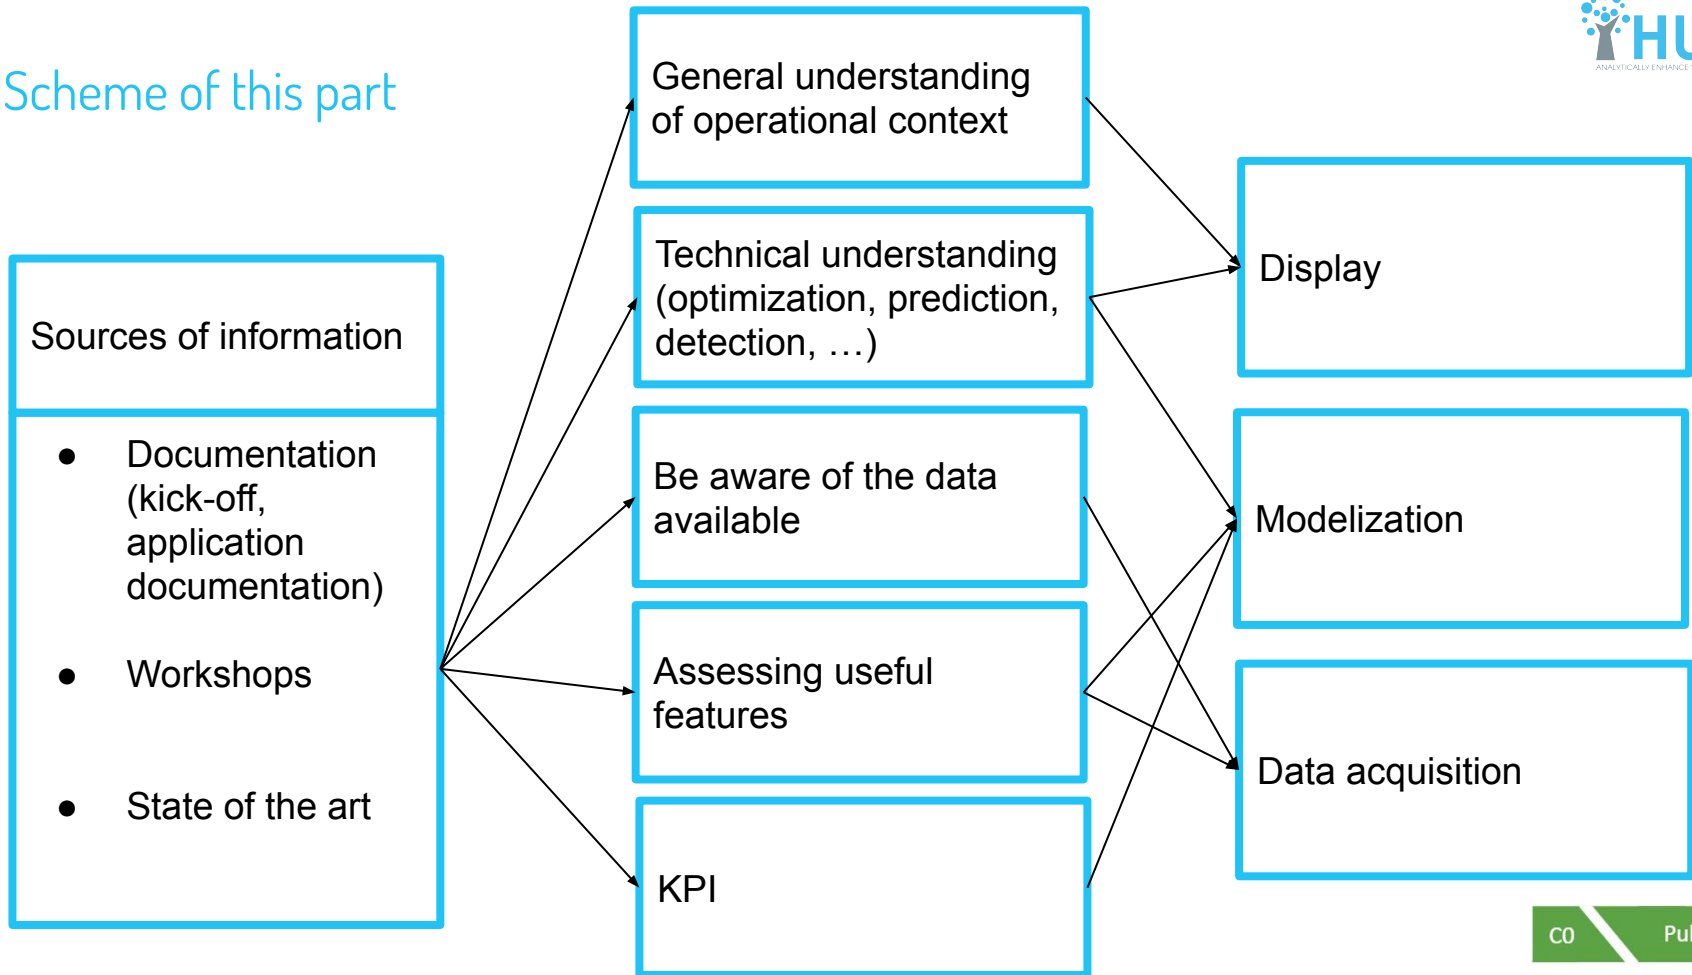


A-Problem understanding

POSSIBLE ROADMAP

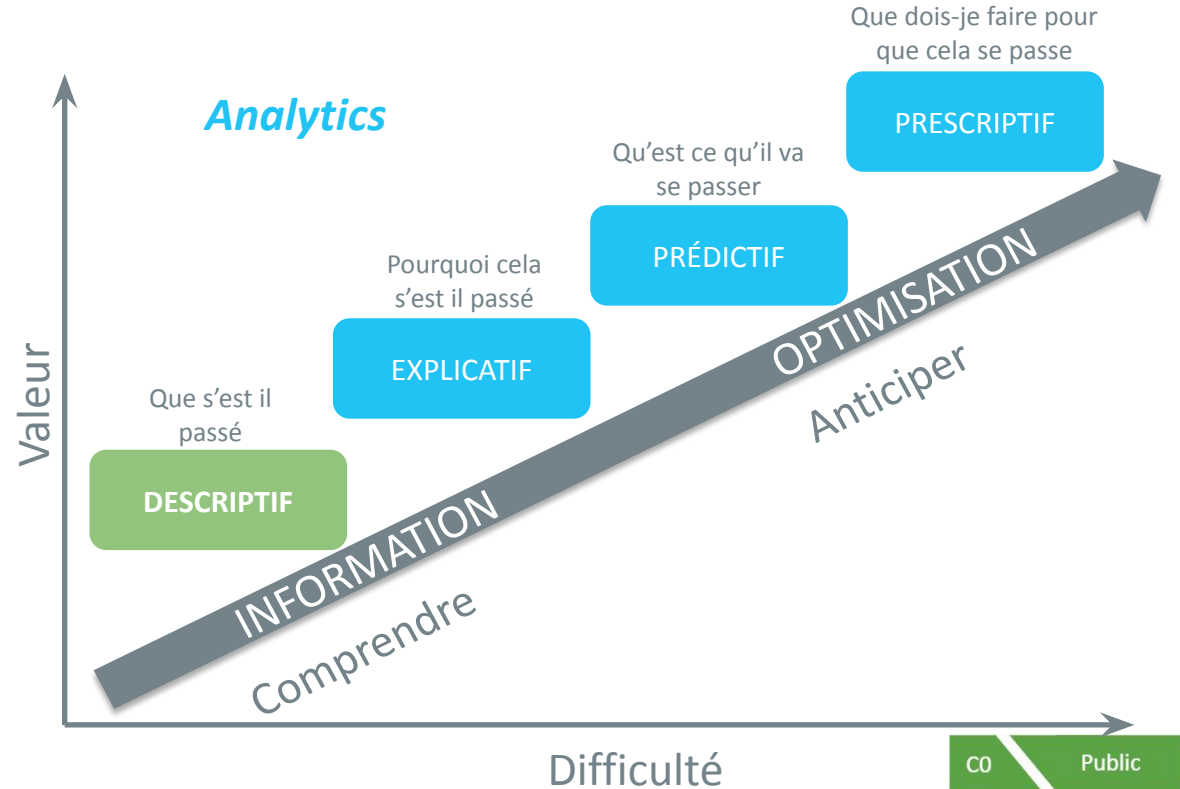


Scheme of this part



Spécifications de la solution

Dans le machine learning il y a 4 familles d'assistant virtuel, chacun dépendant de l'étape précédente. Pour faire un assistant poussant de la prescription, il faut du prédictif, de l'explicatif et du descriptif.




Garita : understanding the project

- 2nd phase of a project
 - Reading documentation about the first phase
 - Breakdown risk prediction (CIR, presentation)

Results based on the training set

Running times over 3 breakdowns of the troquel T0950507



Legend :

- Predicted running time
- Real running time

Results :

- The multiple R squared value : **0.725**
- We can see graphically as well as through the correlation factor that the machine learning model **identifies most of the cases** where the running time diverts from the Weibull estimation.










26

C0

Public

Garita : understanding the project

- Getting to know the goal of the 2nd phase

Partagés avec moi > ... > Production planning > 1000 - Plan		
Nom		
	1100 - COPRO - COPIL	
	Compte rendu - Projet - POC_PROD.docx 	
	Kick - off	2022 - Optimize Planning to minimize setups 
	Hupi - Presentación de aplicaciones Garita.docx 	
	Plannification	2022 - Production Optimization - Budget - Planning 

-> Optimizing the planification to limit setups and breakdowns
Highest production and lowest delay (KPI)

Understanding the project and the operational context

PLANIFICACION SEMANAL S29/S30 2022											Hecho por:	Fecha:		
	Turnos	M27	M25	M26	M20	M18	M17	M21	N1	M33	MOD	Prior	Rev.	1
DOMINGO	22:00										5	1		Centro de Trabajo
	6:00													
LUNES	6:00	0950507	035/036015	009/0100527F10		005/006066		017089	0100504	007/0080565F10	6	2		M25
	14:00		8000			8000		7250				3		M27
		001/0020600	035/036015	015057		005/006066	0010583		0100504	007/0080565F10	6	4		CM2
	22:00			8000					0100504			5		M20
	22:00	033/034015	035/036015	141067F10			0010585F10		0100504		7	6		M26
	6:00	8000		25000			24000					7		M18
MARTES	6:00	033/034015	0600507F10	141067F10		mantenimiento	0010585F10	0030582OP20		37507/38507	6	8		M21
	14:00		4000	380x1,8						6000		9		M29
		033/034015	0600507F10	001/0020565		mantenimiento	0010585F10		0100504	37507/38507	6	10		M28
	22:00		440x2,2	10000										NOTAS
	22:00	0030587	0840507	001/0020565	024089		0010585F10	9559	0100504		7			
	6:00	4500	12000		6000		18000							
MIERCOLES	6:00	0040587	0840507	6554			0030523		0100504	37507/38507	6			
	14:00		4500	4750			2500							
	14:00	0040587	0840507		041/042089	157			0100504	37507/38507	6			
	22:00		515x3		4000	8000								
	22:00	097/0980507F10	857/957F10	0990554	118067	007/008066		9559	0100504		7			
	6:00	10000	8000	8250	6000	10000								
JUEVES	6:00	097/0980507F10	857/957F10		001007F10	007/008066			0100504	027/028015F10	6			
	14:00				20000					8000				
	14:00	097/0980507F10	0010523F10		001007F10	007/008066			0100504	027/028015F10	6			
	22:00		11750											
	22:00	0960507F10	0010523F10		0060581F10	001/0020559F10	001022F10	035/036089	0100504		7			
	6:00	10000			1000	4000	8000	7500						
	6:00	0960507F10	0010523F10	0440587F10			0010583	035/036089	0100504		6			
	14:00			4000			40000							

Assess the data available

Presentación de aplicaciones –

1.1.2.3. Trabajo - (Base de datos: Garita)

Inicio

Procesos

Garita

Participación

Subordinación

Historia

Eventos

Mantenimiento

Tablas

Almacenamiento

Subgrupos

Tablas

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos

Grupos</

Tipo	Descripción
varchar(50)	ID
int	Código del puesto
datetime	Fecha/Hora inicio
datetime	Fecha/Hora fin
int	Indicador sincronizado

Trabajoorden - (Base de datos: Garita)

Tipo	Descripción
int	ID
varchar(50)	ID orden
varchar(100)	Código de la orden
int	Indicador sincronizado

Acción - (Base de datos: Garita)

Tipo	Descripción
varchar(50)	ID acción
varchar(50)	ID trabajo
varchar(10)	Código definición de la acción
datetime	Fecha hora inicio
datetime	Fecha hora fin
int	Indicador sincronizado
int	Indicador bueno validado

Further technical understanding with Galderak

Optimized Production Planning to Reduce Number of Setups

+ Add question

Show 10 entries















Waiting

Done

Cancelled

All

Search:

Question	Reply	Status	Date	
Tambien, es normal que actualmente, solo puedo visualizar la base de datos de izaro y no de garita ? Con la herramienta dbeaver, se muestra un error de nivel de acceso  	No answer yet 	Waiting_ 	05/12/2022	
Otra pregunta : sabeis porque no tengo ninguna informacion sobre la disponibilidad de la maquina M33 (con codigo de centro de trabajo 13301)?  	No answer yet 	Waiting_ 	05/12/2022	
Buenos días, Una pregunta : como podemos saber en que día tenemos solamente 16 horas de produccion y en otros casos 24 (con la noche). En la tabla de los calendarios no es	Es posible, que el calendario, no este bien rellenado. Miramos un caso practico en la reunion de hoy para ver lo que esta pasando.  	Waiting_ 	05/12/2022	

blic

State of the art

- Sci-hub
- Google scholar
- Researchgate
- Kaggle

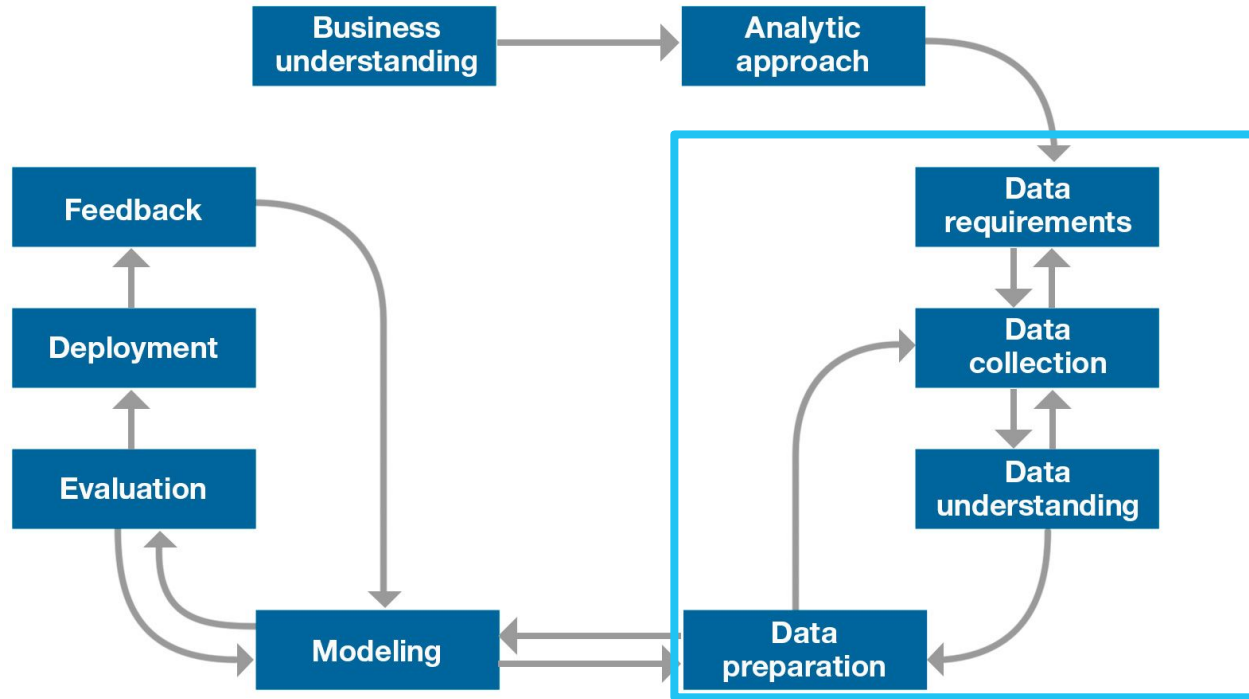
-> what has been done in similar projects ?

-> which technologies are used ?

“Optimizing scheduling with uncertainty”
“Multiple criteria optimization”


B-Data acquisition

ROADMAP



DATA TREATMENT PROCESS PRESENTATION

We will describe the following 4 main steps,



detailing at each step:

1. The work done by data scientists at HUPI
2. The issues we may have & solutions


WORK THROUGHOUT THE PROCESS (1 + 2)

1

Data sources

Objective: access to data

- **API** (for weather, geographical areas, ...)
- **Customers** databases (SQL server, PostgreSQL, Oracle, MySQL)
- **Customers** Excel files, documents, ...
- **Opendata** files



2

Data collection

Objective: save data in Hupi

How to proceed?

Analyze data > Select data > Save data

Where we store data?

- **Mongo DB** → most of the time
- **HDFS** → with big data



CO

Public

WORK THROUGHOUT THE PROCESS (3 + 4)


3

Data preparation

Objective: accurate & clean data

Transformation of raw data into usable data:

1. Identify problems: missing/inconsistent data
2. Cleaning: replace missing data, delete inconsistent data
3. Formatting: dummy encoding of variables, data typing




4

Data analysis

Objective: data validation

Data qualification:

Data exploration: normal behaviour detection / anomaly detection



ONE EXAMPLE : Prediction of bus delays on lines

1

Data sources

Objective: access to data

From a SQL Server :

DBeaver 22.2.3 - kb_145_data_billetique

Jour	timestamp	nb Lit	nb Ligne	123	Nombre
2022-05-16 00:00:00.000	Retour	T1			3
2022-05-16 00:00:00.000	Retour	T1			2
2022-05-16 00:00:00.000	Aller	T1			2
2022-06-27 00:00:00.000	Retour	T2			2
2022-06-27 00:00:00.000	Aller	4			2
2022-05-16 00:00:00.000	Retour	T1			2
2022-05-16 00:00:00.000	Retour	T1			1
2022-05-16 00:00:00.000	Retour	T1			1
2022-05-16 00:00:00.000	Retour	T1			1
2022-05-16 00:00:00.000	Aller	T1			1
2022-05-16 00:00:00.000	Aller	T1			1

2

Data collection

Objective: save data in Hupi

Select data: select priority bus lines and not & filter the routes of buses returning to the depot



Save data:

```
db.getCollection("kb_28_tbCourse").find()
```

Key	Value
kb_28_tbCourse	0.084 sec.
(1) ObjectId("6256e59df2e1ff58cfd9051...") { 12 fields }	
_id	ObjectId("6256e59df2e1ff58cfd90515")
IDCourse	4673284
stJournee	2021-04-13 00:00:00.000Z
szNomCourse	11316
szCodeHastus	727489
szNomLigne	4
stHeureDepTheo	2021-04-13 08:12:00.000Z
stHeureDepReel	2021-04-13 08:11:00.000Z
retard	-60
retardYesNo	avance
units	1618272000
dimTbCourse	257644


3

Data preparation

Objective: accurate & clean data

Identify & clean problems: find & remove outliers

abnormal behaviors: more than 4 hours delay




4

Data analysis

Objective: data validation

Data qualification:
Correlation analysis between data collected and the target



ISSUES & SOLUTIONS THROUGHOUT THE PROCESS

1

Data sources

Objective: access to data

Problems with **database connections**

2

Data collection

Objective: save data in Hupi

Problems of **massive storage**

3

Data preparation

Objective: accurate & clean data

Heterogeneous data to be processed

4

Data analysis

Objective: data validation

Understanding of data

Some solutions provided:

- Exchange with clients to adapt a solution
- Use (& learn) different programming languages to connect

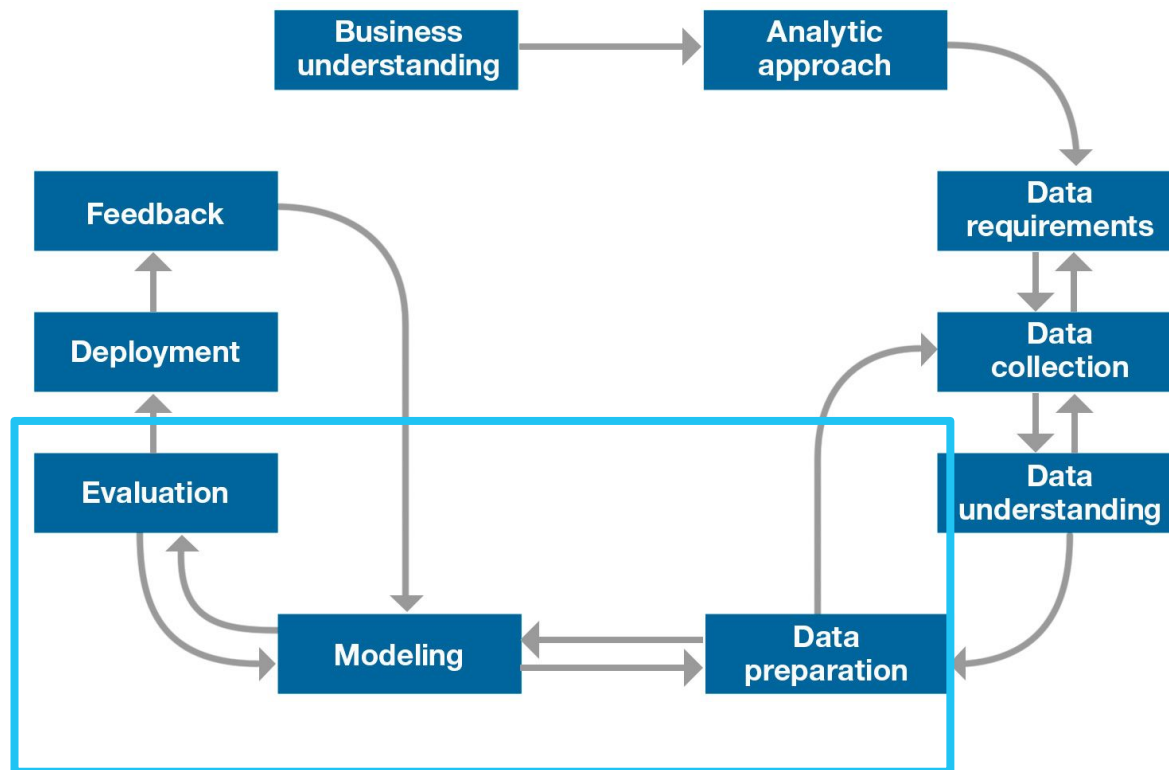
- Use (& learn) the adapted **Spark Scala language**
- Use the power of HUPI's servers

- Clean up data on a case-by-case basis

- Exchange with clients with *galderak-erantzunak* platform
- Search in scientific articles (state of the art)

C-Modeling

POSSIBLE ROADMAP



CREATION OF THE INPUT MATRIX

What is feature selection ?

Feature selection is the process of identifying and selecting the features that contribute the most to the prediction variable or output that you are interested in, either automatically or manually.

Why feature selection ?


To train a model, we collect enormous quantities of data to help the machine learn better. Usually, a good portion of the data collected is noise, while some of the columns of our dataset might not contribute significantly to the performance of our model.

Further, having a lot of data can slow down the training process and cause the model to be slower. The model may also learn from this irrelevant data and be inaccurate.


	nightly_rate	property_id	nb_persons	nb_rooms
bien_id	0.089367	1.000000	0.043811	0.114561
mois	-0.005908	0.113943	-0.033987	-0.002945
price	0.981738	0.086359	0.361230	0.361920
pallier	0.981480	0.086491	0.360879	0.361859
nightly_rate	1.000000	0.089367	0.366480	0.371866
property_id	0.089367	1.000000	0.043811	0.114561
nb_persons	0.366480	0.043811	1.000000	0.793961
nb_rooms	0.371866	0.114561	0.793961	1.000000
nb_bedrooms	0.357416	0.118441	0.791099	0.982245
nb_bathroom	0.464984	0.099750	0.640176	0.651123
surface	0.397884	0.112158	0.561888	0.632538
sauna	0.222732	0.024847	0.132082	0.125360
balcony	0.056192	-0.007349	-0.007999	-0.196050
tennis	0.000290	-0.004638	0.034187	0.053254
pets	-0.072950	-0.098369	0.012027	-0.021015
fireplace	0.156403	0.016723	0.297880	0.376675

CHOICE OF MODEL

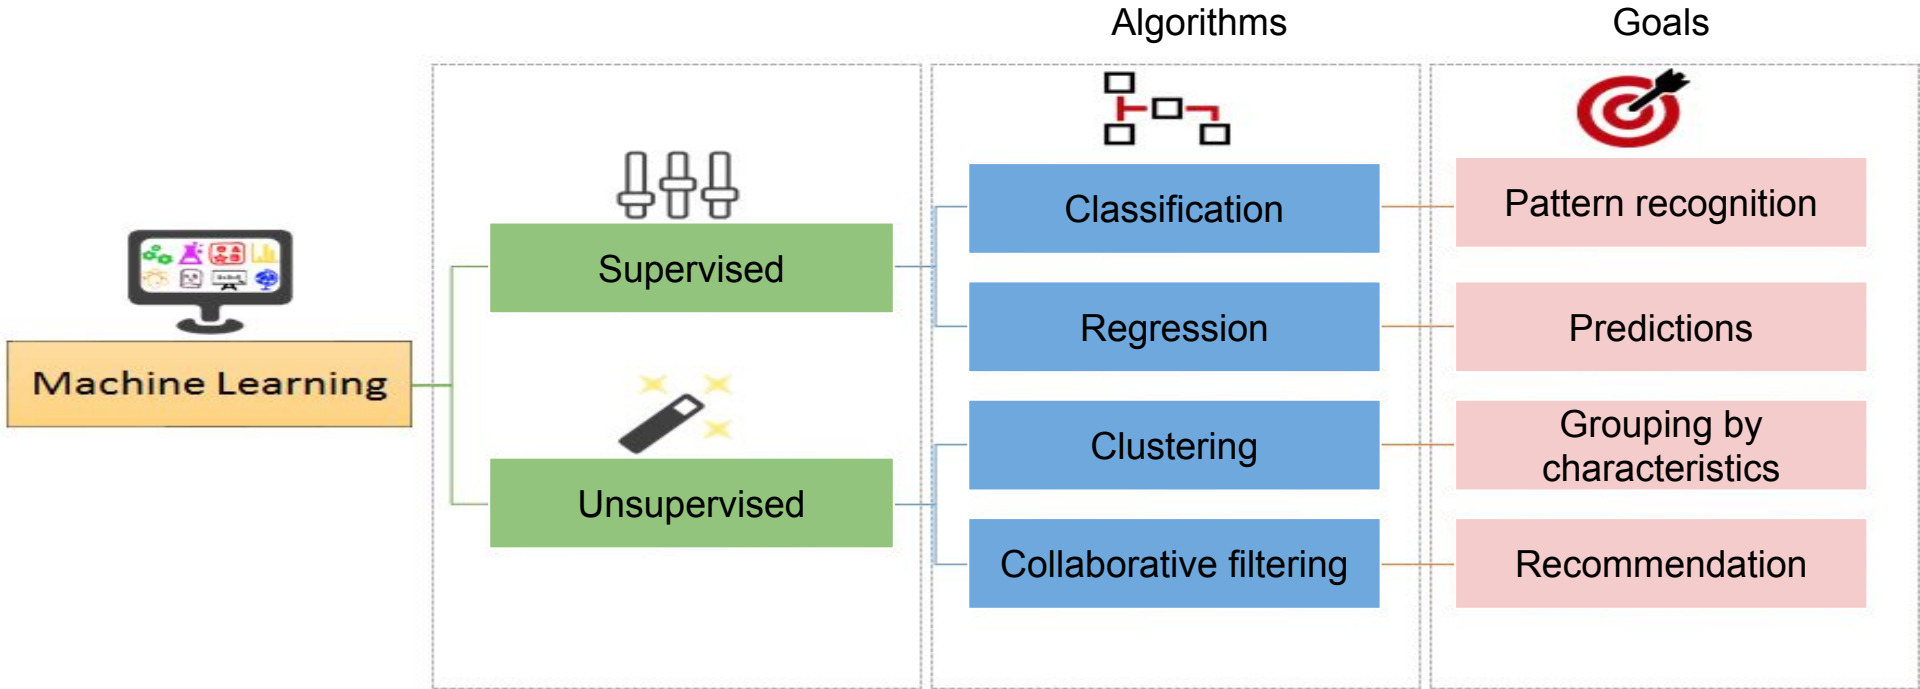
(a) Training



(b) Prediction



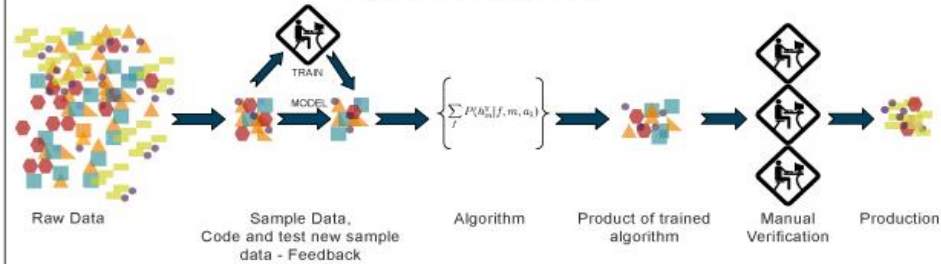
CHOICE OF MODEL



SUPERVISED VS UNSUPERVISED LEARNING

SUPERVISED LEARNING

Reliance on algorithm trained by human input, reduced expenditure on manual review for relevance and coding




E-Discovery Concepts: Machine Learning

Hudson LEGAL

UNSUPERVISED LEARNING

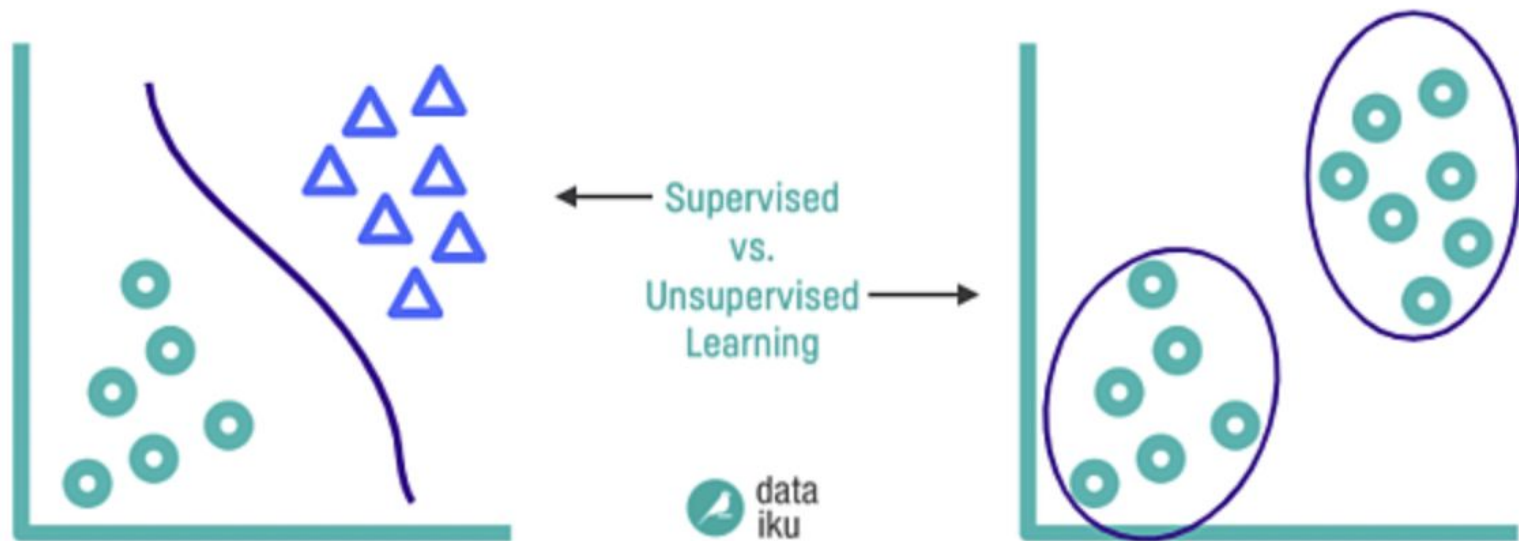
High reliance on algorithm for raw data, large expenditure on manual review for review for relevance and coding



E-Discovery Concepts: Machine Learning

Hudson LEGAL

SUPERVISED VS UNSUPERVISED LEARNING



Supervised vs. Unsupervised Learning

CREATION OF STATISTICAL AND BUSINESS INDICATORS

Business indicators



Example of KPI : the number of stays sold for a dynamic pricing project

Statistical indicators

Classification :

n=165	Predicted: NO	Predicted: YES
Actual: NO	50	10
Actual: YES	5	100

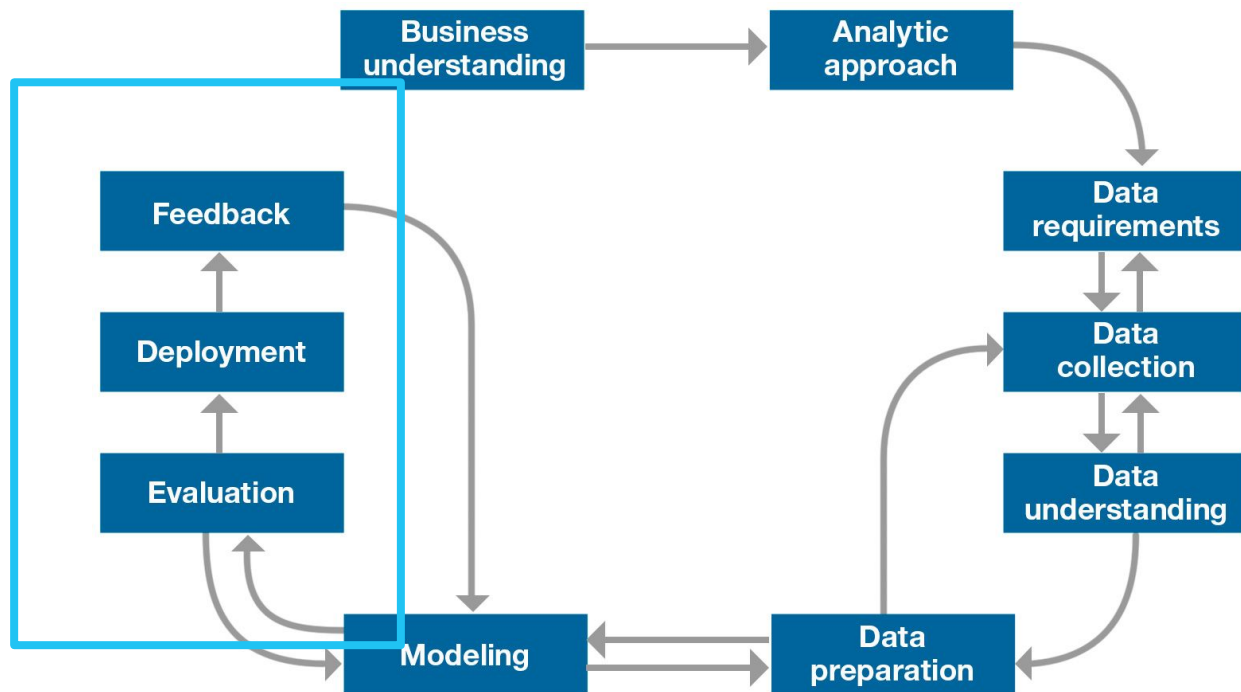
Regression metrics :

- R^2
- RMSE (Root Mean Squared Error)
- MAE (Mean Absolute Error)

Model performance increase doesn't always mean business growth. Monitoring and correlation AI model metrics with the business KPIs help in bridging the gap between performance analysis and business growth, integrating the whole enterprise to function more efficiently towards a set objective.

D-Display/Restitution

POSSIBLE ROADMAP

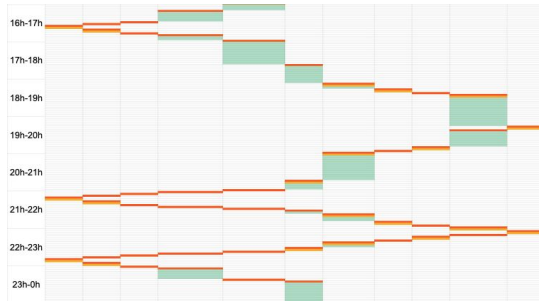


RESTITUTION OF THE RESULTS


Data sources

Objective: share data


- **API** with HUPI Front
- **Widgets** on HUPI Front
- **Files** Excel files, documents, Slides ...
- **Notebooks** Zeppelin



Excel file - EGIS



Graphic line - Loire Gestamp



Bar plot - Keolis-Bayonne

DEPLOYMENT

1


Containerization
Objective: quick and efficient deployment of applications and models



In HUPI's servers or client's servers !

2

Automatization
Objective: Run the jobs on automatically at a defined frequency




ex: Training 1 x month
Predictions 1 x day

MONITORING






Checks the performance evolution
of the models
Objective: Detect Big changes


Mois	Valeur prédite	Valeur réelle	Taux d'erreur
Février	234929.0	66420.0	253.7 %
Janvier	542290.0	471927.0	14.91 %
Décembre	553806.0	551063.0	0.5 %
Novembre	544990.0	543119.0	0.34 %

Error percentage of passengers number prediction - Keolis Bayonne



Supervise the models
Objective: Detect bugs

<input type="checkbox"/>	 zabbix	Notifications/Zabbix	Resolved in 4h 38m 11s: KEOLIS : No temperature data logstash is freezing - Problem ...	08:36
<input type="checkbox"/>	 notifications-plate.	notification-platefo...	Airflow alert: <TaskInstance: ges_200_alert_nitrodines_recommendation.alert_ni...	08:32
<input type="checkbox"/>	 notifications-plate.	notification-platefo...	Airflow alert: <TaskInstance: ges_200_alert_nitrodines_recommendation.alert_ni...	08:31
<input type="checkbox"/>	 notifications-plate.	notification-platefo...	Airflow alert: <TaskInstance: ges_200_alert_nitrodines_recommendation.alert_ni...	08:30
<input type="checkbox"/>	 notifications-plate.	notification-platefo...	Airflow alert: <TaskInstance: ges_200_alert_nitrodines_recommendation.alert_ni...	08:29



Weekly Meetings

Objective: Vulgarize results with the clients

- **Frequency** \approx 30 min each week
- **Support** Notebooks, slides, documents ...
- **Decisions**
 - Add additional features
 - Bug reports
 - Suggestions for improvements



New version of the model !